

2026년 5월 AI SECURITY REPORT

AI 보안 위협 월간 보고서

최근 1개월 핵심 동향과 대응 포인트



프론티어 모델의 사이버 능력 급상승



AI 인프라 취약점, 시간 단위로 무기화



한국도 AI 보안 주권 대응 본격화

기준일: 2026.05.20





한국의 대응

AI 보안 주권이 정책 의제로 올라오다



04.15 금융위

금융권 CISO 비상 소집,
7월 D-day 설정



05.08 과기정통부

산학연 긴급 회의,
AI 보안 주권 공감대



05.11 정부-Anthropic

Glasswing 참여 요청



05.18~19 정부-OpenAI

TAC 협력 큰 틀 합의



KISA 사례

Claude Opus 4.7로
10분 만에 7건 취약점 발견



의미: 기술 접근 전략, 제도 정비, 공급망 보안이 동시에 추진되어야 한다.

미토스의 역설

능력은 급상승했지만, 통제 전략은 흔들렸다

능력 상승



제한적 배포: Project Glasswing



공격적 취약점 탐지·익스플로잇 능력



기업·기관 중심 통제된 롤아웃

통제 실패 신호



2026.03

내부 데이터 노출



2026.03~04

Claude Code 소스맵 유출



2026.04.07

Mythos 무단 접근



시사점: 코어 모델뿐 아니라 공급망·협력업체·배포 파이프라인까지 함께 통제해야 한다.

핵심 위협 분석

우선순위 기준으로 본 위험 지도



P1

즉시 대응



LiteLLM SQLi



MCP RCE 체인



EchoLeak / Copilot



Semantic Kernel prompt-to-code



GPT-5.5 jailbreak



P2

30일 이내



LangSmith AgentSmith



Memory/Context Poisoning



RAG 벡터 포이즈닝



Hugging Face 공급망



Langflow RCE



한국어 보이스피싱



P3

90일 이내



Unbounded Consumption



LLMjacking




장기 거버넌스 정비



INSIGHT

공통 분모: 에이전트화가 진행될수록 프롬프트·도구·메모리·공급망이 모두 공격면이 된다.





마지막 한 문장

패치보다 빠른 AI, 운영보다 중요한 거버넌스



능력 경쟁은 이미 시작됐다



병목은 발견이 아니라 패치·통제·운영이다



2026년의 승부처는 agentic AI 안전 운영 역량이다



보안팀 · AI팀 · 정책팀을 하나의 운영 체계로 묶어야 한다



주요 사건 타임라인

한 달 동안 확인된 대표 사례




패턴: 취약점 공개 → PoC → 운영 위협으로 이어지는 시간이 급격히 짧아짐



프론티어 모델 비교

Mythos vs GPT-5.5



Mythos



출시/공개: 2026.04.07 / Glasswing 제한 접근



강점: 취약점 탐지·익스플로잇 자동화



사례: Firefox 271건, FreeBSD NFS RCE



한국 접근: 현재 미참여

GPT-5.5



출시/공개: 2026.04.23 / ChatGPT·API + TAC



분류: Cybersecurity High



성능: Cyber range 93.33%, Expert Tier 71.4%



우려: universal jailbreak, agentic 우회




정리: 미토스는 더 제한적이지만 공격성이 강하고, GPT-5.5는 접근성이 높아 즉시 위협 관점에서 더 중요하다.



이번 달 핵심 동향

AI 보안 환경이 바뀌는 4가지 신호



프론티어 모델 동시 도래

Mythos와 GPT-5.5가
보안 평가 기준을 끌어올림



익스플로잇 사이클 단축

취약점 공개 후 무기화까지
며칠이 아니라 '시간' 단위



프롬프트가 곧 실행 경로

에이전트·프레임워크에서
prompt-to-shell /
prompt-to-code 위험 확대



한국 대응 본격화

정부·금융·공공이 AI 보안
주권과 접근 전략을 논의 시작



핵심 메시지: 모델 성능 경쟁보다 운영 통제와 대응 속도가 더 중요해졌다.



Claude Mythos Preview

사이버 보안 특화 프론티어 모델의 등장



공개 시점

2026.04.07



배포 방식

Glasswing 제한 접근 /
일반 공개 계획 없음



Firefox 취약점

271건 발견 · 181건 exploit 개발



핵심 사례

FreeBSD NFS RCE,
OpenBSD 27년 결함



UK AISI 평가

TLO 32단계 10회 중 3회 완전 해결



의미: 취약점 발견과 익스플로잇 자동화 능력이
새로운 수준에 도달했다.



권고 로드맵

지금 해야 할 일, 30일 안에 할 일, 90일 안에 할 일



P1 즉시

- AI 인프라 패치
- TAC 즉시 신청 + Glasswing 외교
- jailbreak 다층 방어
- Copilot/RAG 외부 발신 차단
- MCP 격리



P2 30일

- 자율 에이전트 거버넌스
- AI 공급망 허용목록
- 딥페이크·보이스피싱 대응
- RAG 메모리 무결성
- EU AI Act 대비



P3 90일

- 한국 AI 기본법 통합 점검
- 비용·키 위생
- OT 환경 AI 가이드 정렬



핵심은 기술 도입이 아니라 안전한 운영 체계를 만드는 것이다.